
System Architecture

HR Assistant

Dokumentasi teknis arsitektur, alur runtime, data, keamanan,
dan deployment aktual HR Assistant.

Contents

1 Konteks Sistem	3
1.1 Tujuan dan Ruang Lingkup	3
1.2 Fitur Inti	3
1.3 Tech Stack	3
2 Struktur Repository	4
3 Ringkasan Arsitektur	5
3.1 Keputusan Utama	5
3.2 Komponen Kode Inti	5
3.3 API Overview	6
4 Diagram Arsitektur Sistem	7
5 Data dan Konfigurasi	8
5.1 Model Data Inti	8
5.2 Konfigurasi Wajib	8
6 Alur Chat End-to-End	9
7 Alur Ingestion Dokumen	10
8 Keamanan dan Otorisasi	11
9 Deployment Aktual EC2	12
9.1 Instance dan Host	12
9.2 Network dan Reverse Proxy	12
9.3 Container dan Persistent Storage	13
10 Dependency dan Catatan Operasional	14
10.1 Proses Update	14
11 Skalabilitas dan Keterbatasan	15
12 Rekomendasi	16

1 Konteks Sistem

1.1 Tujuan dan Ruang Lingkup

HR Assistant adalah aplikasi internal berbasis RAG untuk mencari informasi dari SOP, kebijakan HR, dan panduan perusahaan melalui antarmuka percakapan. Jawaban menyertakan citation dan form download ketika tersedia. Admin mengelola dokumen, FAQ, guardrails, activity log, feedback, serta analytics.

Area	Kondisi aktual
Runtime	Monolith FastAPI pada satu EC2; frontend utama disajikan sebagai static files.
Data	PostgreSQL untuk state dan analytics; ChromaDB lokal untuk document index dan semantic cache.
AI	9Router/Kiro untuk chat completion, Nscale untuk embedding, dan Langfuse opsional untuk tracing.
Akses	Satu Google sign-in flow. Role admin berasal dari kecocokan email pada <code>app.admin_accounts</code> .
Batas implementasi	HTTPS dan SAML tidak diimplementasikan. Tidak ada HA atau pipeline CI/CD terkelola.

1.2 Fitur Inti

- Chat RAG dengan conversation history, citations, dan form recommendations.
- Context resolution untuk follow-up question dan semantic cache setelah thumbs-up.
- Upload dokumen, reindex, FAQ, guardrails, feedback, activity log, dan analytics admin.
- Optional reranking dan diagram description jika dependency tersedia.

1.3 Tech Stack

Layer	Teknologi
Backend	Python 3.11, FastAPI, SQLAlchemy, Alembic, ChromaDB
Frontend (User)	Vanilla JS SPA, static HTML/CSS/JS
Frontend (Admin)	React 18, Vite, Recharts
Database	PostgreSQL 16
Vector Store	ChromaDB (persistent local)
AI/LLM	Claude via 9Router/Kiro (OpenAI-compatible API)
Embeddings	Nscale (OpenAI-compatible endpoint)
Observability	Langfuse (optional tracing)
Infrastructure	AWS EC2 (t3.medium), Docker Compose, Nginx

2 Struktur Repository

```

<project-root>/
|-- backend/
|   |-- api/
|   |   |-- main.py           # FastAPI routes, auth, storage, models
|   |   |-- core.py          # Application entry point
|   |   |-- routes_public.py  # App factory, middleware, static mounts
|   |   |-- routes_admin.py   # Query, conversations, download
|   |   |-- routes_auth.py    # Documents, reindex, FAQ, logs
|   |   |-- routes_auth.py    # Google login flow
|   |   |-- routes_analytics.py # Analytics dashboard routes
|   |   |-- auth.py           # HMAC session + Google verification
|   |   '-- storage.py        # Document and form management
|   |-- researcher_crew/
|   |   '-- src/researcher_crew/
|   |       |-- main.py       # RAG orchestrator
|   |       |-- context_graph.py
|   |       |-- context_schema.py
|   |       '-- tools/custom_tool.py
|   |-- preprocessing/
|   |   |-- ingest.py         # Ingestion entry point
|   |   |-- loader.py         # PDF/DOCX/TXT loader
|   |   |-- chunker.py        # AI chunking + fallback
|   |   |-- diagram_description.py
|   |   |-- embedding.py      # Nscale embeddings
|   |   '-- vectorstore.py    # ChromaDB index
|   |-- analytics/           # Topic and aggregate processing
|   |-- db/
|   |   |-- models.py         # SQLAlchemy ORM
|   |   |-- engine.py         # Synchronous engine/session
|   |   |-- repository.py     # Database operations
|   |   '-- alembic/          # Migration scripts
|   |-- data/                # Source documents and forms
|   |-- settings.py          # Environment helpers
|   |-- semantic_cache.py
|   '-- observability.py
|-- frontend/
|   |-- web/                 # Main static SPA
|   '-- dashboard/           # React/Vite analytics source
|-- deploy/
|   |-- nginx/hr-agent.conf  # Reverse proxy config
|   '-- update-ec2.sh        # EC2 update script
|-- docs/                   # Architecture and admin guide
|-- docker-compose.yml      # Production services
|-- docker-compose.dev-db.yml # Local development PostgreSQL
|-- Dockerfile
|-- alembic.ini
|-- requirements.txt
|-- .env.example
|-- run.bat
'-- clean.bat

```

3 Ringkasan Arsitektur

3.1 Keputusan Utama

- **Auth:** semua account login dengan Google; admin ditentukan oleh `app.admin_accounts`.
- **Session:** token HMAC-SHA256 berlaku 12 jam; role diperiksa kembali dari PostgreSQL.
- **Data:** PostgreSQL menjadi source of truth; ChromaDB menyimpan document vectors dan semantic cache.
- **Retrieval:** semantic search dengan optional rerank; jawaban baru di-cache setelah thumbs-up.
- **Runtime:** single-instance deployment dipilih untuk operasional sederhana saat ini.

3.2 Komponen Kode Inti


Komponen	Tanggung jawab
backend/api/*	FastAPI app, auth, user/admin/analytics routes, storage, FAQ, dan forms.
backend/ researcher_crew/*	Context graph, retrieval, prompt, dan orchestrator jawaban.
backend/preprocessing/*	Loader, visual description, chunking, embedding, dan vector store.
backend/db/*	SQLAlchemy synchronous ORM, repository, engine, dan Alembic.
backend/analytics/*	Topic classification, canonical interactions, dan daily aggregates.
frontend/web, frontend/dashboard	SPA utama vanilla JS dan dashboard admin React/Vite.

3.3 API Overview

Semua endpoint berada di bawah FastAPI monolith pada port 8000. Autentikasi menggunakan session token di header.

Method	Endpoint	Deskripsi
POST	/api/auth/google	Login via Google ID token, return session.
POST	/api/query	Kirim pertanyaan ke RAG pipeline.
GET	/api/conversations	List conversation history user.
GET	/api/conversations/:id	Detail messages pada conversation.
POST	/api/feedback	Submit feedback (thumbs up/down).
GET	/api/admin/documents	List dokumen yang dikelola.
POST	/api/admin/documents	Upload dokumen baru.
POST	/api/admin/reindex	Trigger reindex embedding.
GET	/api/admin/faq	List FAQ items.
GET	/api/admin/logs	Activity log dan session history.
GET	/api/admin/analytics/*	Analytics data (overview, charts, topics).
GET	/health	Basic health check.

4 Diagram Arsitektur Sistem



Dependency runtime utama; external services ditandai outline merah.

5 Data dan Konfigurasi


5.1 Model Data Inti

Tabel	Peran
app.users, app.admin_accounts	Identitas Google dan allowlist role admin tanpa password.
app.conversations, app.conversation_messages	Riwayat chat dan metadata jawaban, citation, serta form.
app.feedback, app.faq_items	Rating jawaban dan FAQ berbasis knowledge base.
app.activity_logs, app.cache_entries	Audit produk dan metadata semantic cache.
analytics.canonical_ interactions	Interaksi ternormalisasi untuk analytics.
analytics.daily_topic_ aggregates	Rollup harian topic, user, feedback, dan fallback/error.
app.app_state_meta	Session signing, guardrails, dan metadata state.

5.2 Konfigurasi Wajib


Variable / group	Fungsi
DATABASE_URL	PostgreSQL connection string.
MODEL, CHAT_BASE_URL	Model chat dan endpoint 9Router/OpenAI-compatible.
NSCALE_SERVICE_TOKEN, EMBED_MODEL	Credential dan model embedding.
GOOGLE_CLIENT_ID	Verifikasi Google login dan rendering sign-in.
DATA_DIR, CHROMA_DIR, SEMANTIC_CACHE_DIR	Source documents dan persistent vector stores.
LANGFUSE_*	Tracing opsional; switch default aktif dan IO mode masked.

6 Alur Chat End-to-End



Alur utama (atas) dan jalur alternatif (bawah); cache hanya diperbarui setelah feedback positif.

7 Alur Ingestion Dokumen




Alur ingestion utama (atas); sidecar PDF dan fallback chunking ditampilkan di baris bawah.

8 Keamanan dan Otorisasi

Kontrol	Implementasi aktual
Authentication	Google ID token untuk semua user/admin; hosted domain divalidasi.
Admin role	Email pada <code>app.admin_accounts</code> berarti admin; email lain berarti user.
Session	HMAC-SHA256, expiry 12 jam, secret acak di PostgreSQL; logout menghapus sesi lokal dan menonaktifkan Google auto-select.
Authorization	FastAPI dependencies membedakan user/admin dan memeriksa row user live.
File handling	Validasi extension, ukuran, path traversal, document kind, dan replacement path.
Privacy	Analytics memakai pseudonymous user ID; Langfuse masked mode meredaksi pola sensitif.
Gap	Belum ada rate limiting, server-side token revocation list, dependency scan, atau TLS termination.

9 Deployment Aktual EC2



Deployment aktual pada satu EC2 instance; semua container berjalan dalam satu Docker Compose stack.

9.1 Instance dan Host

Aspek	Nilai aktual
Public hostname	ec2-98-81-149-80. compute-1.amazonaws.com
Instance / lokasi	t3.medium, Availability Zone us-east-1c
OS / kernel	Amazon Linux 2023.12; kernel 6.18 x86_64
Compute	2 vCPU, RAM 3.7 GiB, tanpa swap
Root storage	EBS 25 GiB, XFS; 12 GiB terpakai (45%) saat audit
Runtime tools	Docker 25.0.14, Compose 5.3.1, Nginx 1.30.3
Repository checkout	Branch <code>main</code> , revision <code>f36db57</code> saat audit

9.2 Network dan Reverse Proxy

Nginx aktif dan menerima HTTP pada port 80, dengan `client_max_body_size` 50M, lalu meneruskan request ke `127.0.0.1:8000`. SSH mendengarkan port 22. PostgreSQL (5432), 9Router (20128), dan FastAPI (8000) hanya bind ke loopback host.

Instance memakai Security Group `sg-06ef9252c75a9d9e9`. Akses inbound HTTP/SSH dibatasi ke public egress jaringan kantor berdasarkan konfirmasi owner, sehingga aplikasi tidak ditujukan untuk akses internet umum.

9.3 Container dan Persistent Storage

Service	Image / port	Kondisi saat audit
app	Custom 127.0.0.1:8000	app; Up 10 hari; restart unless-stopped ; belum memiliki Docker healthcheck.
9router	decolua/ 9router:latest; 127.0.0.1:20128	Up 10 hari; restart unless-stopped ; tanpa healthcheck.
9router-loopback	alpine/ socat:latest	Up 10 hari; forward internal; tanpa healthcheck.
postgres	postgres:16-alpine; 127.0.0.1:5432	Up 10 hari dan healthy; restart unless-stopped .
Docker volume	Penggunaan saat audit	
App storage volume	49 MiB; menyimpan source documents dan ChromaDB.	
PostgreSQL data volume	48 MiB; data PostgreSQL self-hosted pada instance yang sama.	

PostgreSQL production aktual berjalan sebagai container lokal pada EC2, bukan RDS. App, database, documents, dan vector index tetap memiliki satu failure domain.

10 Dependency dan Catatan Operasional

Area	Catatan penting
Nscale	Embedding API masih memakai akun pribadi. Kehilangan akses menghentikan ingestion dan semantic retrieval yang membutuhkan embedding baru.
9Router / Kiro	Bergantung pada Kiro/AWS Builder ID di host; image memakai tag latest .
Google OAuth	Wajib untuk membuat sesi user maupun admin baru.
Langfuse	Opsional dan fail-open; switch default aktif, tetapi trace hanya dikirim jika key dan base URL tersedia.
Security Group	sg-06ef9252c75a9d9e9 ; akses office-only dikonfirmasi owner.
HTTPS	Belum aktif; Nginx hanya listen port 80 dan tidak ditemukan TLS certificate/termination pada host.
Health	Hanya PostgreSQL memiliki Docker healthcheck. Endpoint app /health belum memeriksa dependency.

10.1 Proses Update

Script `deploy/update-ec2.sh` membackup konfigurasi, memvalidasi Compose, menjalankan rebuild/recreate container, menerapkan Alembic migration, memeriksa 9Router/model, lalu melakukan polling **/health**. Semua container memakai restart policy **unless-stopped**.

11 Skalabilitas dan Keterbatasan

Aspek	Kondisi saat ini
Concurrent users	Single-instance FastAPI dengan synchronous ORM; cocok untuk internal use (<50 concurrent users).
Horizontal scaling	Tidak didukung — ChromaDB lokal dan session di memori menghalangi multi-instance.
Database	PostgreSQL container lokal; belum ada connection pooling atau read replica.
Vector store	ChromaDB bersifat embedded; untuk skala lebih besar perlu migrasi ke managed vector DB (e.g., Pinecone, pgvector).
Storage	EBS 25 GiB shared antara OS, app, dan data; perlu monitoring kapasitas.
Bottleneck utama	LLM API latency dan embedding API menjadi limiting factor untuk response time, bukan compute lokal.
Path to scale	Jika perlu scaling: pisahkan database ke RDS, gunakan managed vector store, dan tambahkan load balancer di depan multiple app instances.

Catatan kapasitas

Dengan t3.medium (2 vCPU, 3.7 GiB RAM) dan single-process deployment, sistem mampu melayani operasi internal sehari-hari. Peningkatan beban signifikan memerlukan revisi arsitektur pada layer database dan vector store terlebih dahulu.

12 Rekomendasi

Rekomendasi	Alasan
Migrasikan Nscale	Embedding API masih menggunakan akun pribadi — perlu dipindahkan ke akun organisasi agar tidak bergantung pada satu individu.
Aktifkan HTTPS	Saat ini traffic berjalan plain HTTP. Perlu TLS termination agar komunikasi terenkripsi.
Perbaiki deployment	Deployment saat ini hanya menggunakan satu EC2 tanpa load balancer, auto-scaling, atau redundansi. Image container masih memakai tag <code>latest</code> tanpa versioning.
Kelola infrastructure as code	Security group dan konfigurasi network belum didefinisikan sebagai code, sehingga sulit diaudit dan direproduksi.
Tambah health check dan alerting	Hanya PostgreSQL yang memiliki healthcheck. Perlu monitoring dependency-aware dan alerting untuk error rate, disk, dan availability.