
System Architecture

HR Assistant

Akram

ICS Compute — Internship Program 2026

August 13, 2026

Dokumentasi teknis arsitektur, alur runtime, data, keamanan,
dan deployment aktual HR Assistant.

Contents

1 Konteks Sistem	3
1.1 Tujuan dan Ruang Lingkup	3
1.2 Fitur Inti	3
2 Ringkasan Arsitektur	4
2.1 Keputusan Utama	4
2.2 Komponen Kode Inti	4
3 Diagram Arsitektur Sistem	5
4 Data dan Konfigurasi	6
4.1 Model Data Inti	6
4.2 Konfigurasi Wajib	6
5 Tampilan Aplikasi	7
6 Alur Chat End-to-End	8
7 Alur Ingestion Dokumen	9
8 Keamanan dan Otorisasi	10
9 Deployment Aktual EC2	11
9.1 Instance dan Host	11
9.2 Network dan Reverse Proxy	11
9.3 Container dan Persistent Storage	12
10 Dependency dan Catatan Operasional	13
10.1 Proses Update	13
11 Lima Rekomendasi Utama	14
12 Struktur Repository	15

1 Konteks Sistem

1.1 Tujuan dan Ruang Lingkup

HR Assistant adalah aplikasi internal berbasis RAG untuk mencari informasi dari SOP, kebijakan HR, dan panduan perusahaan melalui antarmuka percakapan. Jawaban menyertakan citation dan form download ketika tersedia. Admin mengelola dokumen, FAQ, guardrails, activity log, feedback, serta analytics.

Area	Kondisi aktual
Runtime	Monolith FastAPI pada satu EC2; frontend utama disajikan sebagai static files.
Data	PostgreSQL untuk state dan analytics; ChromaDB lokal untuk document index dan semantic cache.
AI	9Router/Kiro untuk chat completion, Nscale untuk embedding, dan Langfuse opsional untuk tracing.
Akses	Satu Google sign-in flow. Role admin berasal dari kecocokan email pada <code>app.admin_accounts</code> .
Batas implementasi	HTTPS dan SAML tidak diimplementasikan. Tidak ada HA atau pipeline CI/CD terkelola.

1.2 Fitur Inti

- Chat RAG dengan conversation history, citations, dan form recommendations.
- Context resolution untuk follow-up question dan semantic cache setelah thumbs-up.
- Upload dokumen, reindex, FAQ, guardrails, feedback, activity log, dan analytics admin.
- Optional reranking dan diagram description jika dependency tersedia.

2 Ringkasan Arsitektur


2.1 Keputusan Utama

- **Auth:** semua account login dengan Google; admin ditentukan oleh `app.admin_accounts`.
- **Session:** token HMAC-SHA256 berlaku 12 jam; role diperiksa kembali dari PostgreSQL.
- **Data:** PostgreSQL menjadi source of truth; ChromaDB menyimpan document vectors dan semantic cache.
- **Retrieval:** semantic search dengan optional rerank; jawaban baru di-cache setelah thumbs-up.
- **Runtime:** single-instance deployment dipilih untuk operasional sederhana saat ini.

2.2 Komponen Kode Inti

Komponen	Tanggung jawab
backend/api/*	FastAPI app, auth, user/admin/analytics routes, storage, FAQ, dan forms.
backend/ researcher_crew/*	Context graph, retrieval, prompt, dan orchestrator jawaban.
backend/preprocessing/*	Loader, visual description, chunking, embedding, dan vector store.
backend/db/*	SQLAlchemy synchronous ORM, repository, engine, dan Alembic.
backend/analytics/*	Topic classification, canonical interactions, dan daily aggregates.
frontend/web, frontend/dashboard	SPA utama vanilla JS dan dashboard admin React/Vite.

3 Diagram Arsitektur Sistem



Dependency runtime utama; external service ditandai outline merah.

4 Data dan Konfigurasi

4.1 Model Data Inti

Tabel	Peran
app.users, app.admin_accounts	Identitas Google dan allowlist role admin tanpa password.
app.conversations, app.conversation_messages	Riwayat chat dan metadata jawaban, citation, serta form.
app.feedback, app.faq_items	Rating jawaban dan FAQ berbasis knowledge base.
app.activity_logs, app.cache_entries	Audit produk dan metadata semantic cache.
analytics.canonical_ interactions	Interaksi ternormalisasi untuk analytics.
analytics.daily_topic_ aggregates	Rollup harian topic, user, feedback, dan fallback/error.
app.app_state_meta	Session signing secret, guardrails, dan metadata state.


4.2 Konfigurasi Wajib

Variable / group	Fungsi
DATABASE_URL	PostgreSQL connection string.
MODEL, CHAT_BASE_URL	Model chat dan endpoint 9Router/OpenAI-compatible.
NSCALE_SERVICE_TOKEN, EMBED_MODEL	Credential dan model embedding.
GOOGLE_CLIENT_ID	Verifikasi Google login dan rendering sign-in.
DATA_DIR, CHROMA_DIR, SEMANTIC_CACHE_DIR	Source documents dan persistent vector stores.
LANGFUSE_*	Tracing opsional; switch default aktif dan IO mode masked.

Secret tidak boleh di-commit. JWT_SECRET dan API_KEY_SECRET pada production template adalah milik container 9Router, bukan signer token sesi FastAPI.


5 Tampilan Aplikasi

Screenshot berikut menunjukkan dua area operasional utama. Sidebar dipotong agar identitas account internal tidak ikut ditampilkan.



Dashboard analytics

Ringkasan usage, active users, feedback, dan trend pertanyaan.




Document management


Upload, update, delete, dan finalize source documents/form.

Screenshot berasal dari admin guide project dan ditampilkan sebagai konteks visual, bukan sebagai spesifikasi contract frontend.

6 Alur Chat End-to-End



7 Alur Ingestion Dokumen



8 Keamanan dan Otorisasi

Kontrol	Implementasi aktual
Authentication	Google ID token untuk semua user/admin; hosted domain divalidasi.
Admin role	Email pada <code>app.admin_accounts</code> berarti admin; email lain berarti user.
Session	HMAC-SHA256, expiry 12 jam, secret acak di PostgreSQL; logout menghapus sesi lokal dan menonaktifkan Google auto-select.
Authorization	FastAPI dependencies membedakan user/admin dan memeriksa row user live.
File handling	Validasi extension, ukuran, path traversal, document kind, dan replacement path.
Privacy	Analytics memakai pseudonymous user ID; Langfuse masked mode meredaksi pola sensitif.
Gap	Belum ada rate limiting, server-side token revocation list, dependency scan, atau TLS termination.

Invariant auth

Semua account login melalui Google. Jangan mengembalikan admin-password flow atau tombol “Masuk sebagai admin”.

9 Deployment Aktual EC2

Sumber observasi

Inventarisasi read-only melalui SSH pada 13 Agustus 2026. Tidak ada environment secret atau credential container yang dibaca. Security Group ID diperoleh dari IMDS; detail rule tidak dapat ditarik karena host tidak memiliki IAM role/AWS SDK.

9.1 Instance dan Host

Aspek	Nilai aktual
Public hostname	ec2-98-81-149-80. compute-1.amazonaws.com
Instance / lokasi	t3.medium, Availability Zone us-east-1c
OS / kernel	Amazon Linux 2023.12; kernel 6.18 x86_64
Compute	2 vCPU, RAM 3.7 GiB, tanpa swap
Root storage	EBS 25 GiB, XFS; 12 GiB terpakai (45%) saat audit
Runtime tools	Docker 25.0.14, Compose 5.3.1, Nginx 1.30.3
Repository checkout	Branch main, revision f36db57 saat audit

9.2 Network dan Reverse Proxy

Nginx aktif dan menerima HTTP pada port 80, dengan `client_max_body_size` 50M, lalu meneruskan request ke 127.0.0.1:8000. SSH mendengarkan port 22. PostgreSQL (5432), 9Router (20128), dan FastAPI (8000) hanya bind ke loopback host.

Instance memakai Security Group `sg-06ef9252c75a9d9e9`. Akses inbound HTTP/SSH dibatasi ke public egress jaringan kantor berdasarkan konfirmasi owner, sehingga aplikasi tidak ditujukan untuk akses internet umum. Exact CIDR/rule perlu diverifikasi di AWS Console karena instance tidak mempunyai IAM role untuk `DescribeSecurityGroups`.

9.3 Container dan Persistent Storage

Service	Image / port	Kondisi saat audit
app	Custom 127.0.0.1:8000	app; Up 10 hari; restart unless-stopped ; belum memiliki Docker healthcheck.
9router	decolua/ 9router:latest; 127.0.0.1:20128	Up 10 hari; restart unless-stopped ; tanpa healthcheck.
9router-loopback	alpine/ socat:latest	Up 10 hari; forward internal; tanpa healthcheck.
postgres	postgres:16-alpine; 127.0.0.1:5432	Up 10 hari dan healthy; restart unless-stopped .
Docker volume	Penggunaan saat audit	
App storage volume	49 MiB; menyimpan source documents dan ChromaDB.	
PostgreSQL data volume	48 MiB; data PostgreSQL self-hosted pada instance yang sama.	

PostgreSQL production aktual berjalan sebagai container lokal pada EC2, bukan RDS. App, database, documents, dan vector index tetap memiliki satu failure domain.

10 Dependency dan Catatan Operasional

Area	Catatan penting
Nscale	Embedding API masih memakai akun pribadi. Kehilangan akses menghentikan ingestion dan semantic retrieval yang membutuhkan embedding baru.
9Router / Kiro	Bergantung pada Kiro/AWS Builder ID di host; image memakai tag latest .
Google OAuth	Wajib untuk membuat sesi user maupun admin baru.
Langfuse	Opsional dan fail-open; switch default aktif, tetapi trace hanya dikirim jika key dan base URL tersedia.
Security Group	sg-06ef9252c75a9d9e9 ; akses office-only dikonfirmasi owner, sedangkan exact CIDR perlu diverifikasi di AWS Console.
HTTPS	Belum aktif; Nginx hanya listen port 80 dan tidak ditemukan TLS certificate/termination pada host.
Health	Hanya PostgreSQL memiliki Docker healthcheck. Endpoint app /health belum memeriksa dependency.

10.1 Proses Update

Script `deploy/update-ec2.sh` membackup konfigurasi, memvalidasi Compose, menjalankan rebuild/recreate container, menerapkan Alembic migration, memeriksa 9Router/model, lalu melakukan polling **/health**. Semua container memakai restart policy **unless-stopped**.

11 Lima Rekomendasi Utama

Rekomendasi	Alasan dan arah implementasi
Migrasikan Nscale	Pindahkan embedding dari akun pribadi ke akun organisasi atau end-point embedding organisasi yang kompatibel. Pertahankan interface OpenAI-compatible agar perubahan ingestion minimal.
Aktifkan HTTPS	Pasang TLS termination melalui ALB + ACM atau Nginx dengan certificate terkelola, redirect HTTP ke HTTPS, dan dokumentasikan renewal. Pembatasan jaringan kantor tetap dipertahankan.
Perbaiki deployment	Ganti image tag <code>latest</code> dengan versi immutable; tambahkan healthcheck app/9Router, readiness gate, release manifest, dan prosedur rollback yang teruji.
Kelola network sebagai code	Definisikan Security Group dan office CIDR melalui Terraform/CloudFormation; pertimbangkan AWS Systems Manager agar SSH publik dapat diminimalkan.
Lengkapi health dan alerting	Pertahankan Langfuse masked tracing aktif secara default; tambah dependency-aware readiness dan alarm provider, 5xx, disk, serta database.

12 Struktur Repository

```

<project-root>/
|-- backend/
|   |-- api/
|   |   |-- main.py           # FastAPI routes, auth, storage, models
|   |   |-- core.py          # Application entry point
|   |   |-- routes_public.py  # App factory, middleware, static mounts
|   |   |-- routes_admin.py   # Query, conversations, download
|   |   |-- routes_auth.py    # Documents, reindex, FAQ, logs
|   |   |-- routes_auth.py    # Google login flow
|   |   |-- routes_analytics.py # Analytics dashboard routes
|   |   |-- auth.py           # HMAC session + Google verification
|   |   '-- storage.py        # Document and form management
|   |-- researcher_crew/
|   |   '-- src/researcher_crew/
|   |       |-- main.py       # RAG orchestrator
|   |       |-- context_graph.py
|   |       |-- context_schema.py
|   |       '-- tools/custom_tool.py
|   |-- preprocessing/
|   |   |-- ingest.py         # Ingestion entry point
|   |   |-- loader.py         # PDF/DOCX/TXT loader
|   |   |-- chunker.py        # AI chunking + fallback
|   |   |-- diagram_description.py
|   |   |-- embedding.py      # Nscale embeddings
|   |   '-- vectorstore.py    # ChromaDB index
|   |-- analytics/           # Topic and aggregate processing
|   |-- db/
|   |   |-- models.py         # SQLAlchemy ORM
|   |   |-- engine.py         # Synchronous engine/session
|   |   |-- repository.py     # Database operations
|   |   '-- alembic/          # Migration scripts
|   |-- data/                # Source documents and forms
|   |-- settings.py          # Environment helpers
|   |-- semantic_cache.py
|   '-- observability.py
|-- frontend/
|   |-- web/                 # Main static SPA
|   '-- dashboard/           # React/Vite analytics source
|-- deploy/
|   |-- nginx/hr-agent.conf  # Reverse proxy config
|   '-- update-ec2.sh        # EC2 update script
|-- docs/                   # Architecture and admin guide
|-- docker-compose.yml      # Production services
|-- docker-compose.dev-db.yml # Local development PostgreSQL
|-- Dockerfile
|-- alembic.ini
|-- requirements.txt
|-- .env.example
|-- run.bat
'-- clean.bat

```